ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
Khoa Công nghệ Thông tin

BÁO CÁO PHẦN CLASSIFICATION

CSC14005 – Đồ án 1

Dataset chính: *Adult Census Income*

Nhóm: Group_11

Thành viên: Nguyễn Mạnh Thắng – 23120084
Trần Kim Ngọc – 21521062
Nguyễn Thành Nguyên Anh – 23120063
Trần Đình Luân – 23120059
Nguyễn Thiện Nhân – 23120064

Năm học: 2025–2026

TP. Hồ Chí Minh, Ngày 27 tháng 4 năm 2026

Mục lục

1 Thành viên nhóm và phân công công việc **2**

2 Tổng quan classification **3**

2.1 Checklist yêu cầu 3

3 Xây dựng và huấn luyện mô hình **4**

3.1 Logistic Regression nhị phân và Gradient Descent 4

3.2 Newton–Raphson / IRLS 5

3.3 Softmax đa lớp, Jacobian và Hessian 6

3.4 One-vs-rest, one-vs-one và softmax trực tiếp 7

3.5 LDA và QDA 7

3.6 Fisher ratio 9

3.7 Perceptron và regularization 11

4 Bonus models **13**

4.1 Probit 13

4.2 Laplace approximation 14

4.3 Kernel Logistic Regression 15

4.4 GNB vs LDA 15

4.5 VC dimension và SRM 15

5 Đánh giá mô hình **17**

5.1 Metric và công thức 18

5.2 Bảng test metrics thống nhất 18

5.3 Per-class metrics và CV 19

5.4 McNemar's test 21

5.5 Phân tích lỗi 22

6 Phân tích so sánh và kỹ năng nghiên cứu **22**

6.1 Kết nối hồi quy và phân lớp 22

6.2 Bảng so sánh toàn diện 23

6.3 Sensitivity và robustness 24

6.4 Khả năng tái hiện 27

7 Kết luận classification **27**

Tài liệu tham khảo **28**

1. Thành viên nhóm và phân công công việc

Bảng 1: Phân công công việc cho phần Classification.

STT	MSSV	Họ và tên	Nhiệm vụ / Phần đảm nhận	Hoàn thành
1	23120084	Nguyễn Mạnh Thắng	Phụ trách nhóm mô hình Logistic Regression: GD nhị phân, Newton–Raphson/IRLS, softmax đa lớp, OvR/OvO, loss curves và so sánh hội tụ.	100%
2	23120063	Nguyễn Thành Nguyên Anh	Phụ trách nhóm mô hình còn lại và đánh giá: LDA/QDA, Fisher ratio, Perceptron, L1/L2, class-weighted loss, CV, ROC/PR, calibration, McNemar, robustness, bonus và tổng hợp report classification.	100%
3	21521062	Trần Kim Ngọc	Không phụ trách phần classification trong bản report này.	–
4	23120059	Trần Đình Luân	Không phụ trách phần classification trong bản report này.	–
5	23120064	Nguyễn Thiện Nhân	Không phụ trách phần classification trong bản report này.	–

2. Tổng quan classification

Report này chỉ viết cho phần **classification**. Dataset chính là *Adult Census Income*, với nhãn 0 cho thu nhập $\leq 50K$ và nhãn 1 cho thu nhập $> 50K$. Trên tập test, tỷ lệ lớp là $\leq 50K = 75.93\%$ và $> 50K = 24.07\%$, nên đây là bài toán mất cân bằng lớp khoảng 3:1. Vì dataset chính chỉ là nhị phân, các yêu cầu đa lớp và phi tuyến được kiểm tra thêm bằng dữ liệu tổng hợp có kiểm soát.

Các hình trong report được trích trực tiếp từ output của `code/Part2_Classification/notebook.ipynb` và lưu trong `report/figures/classification_outputs`. Các bảng số liệu được chép từ output notebook hoặc artifact CSV của phần classification.

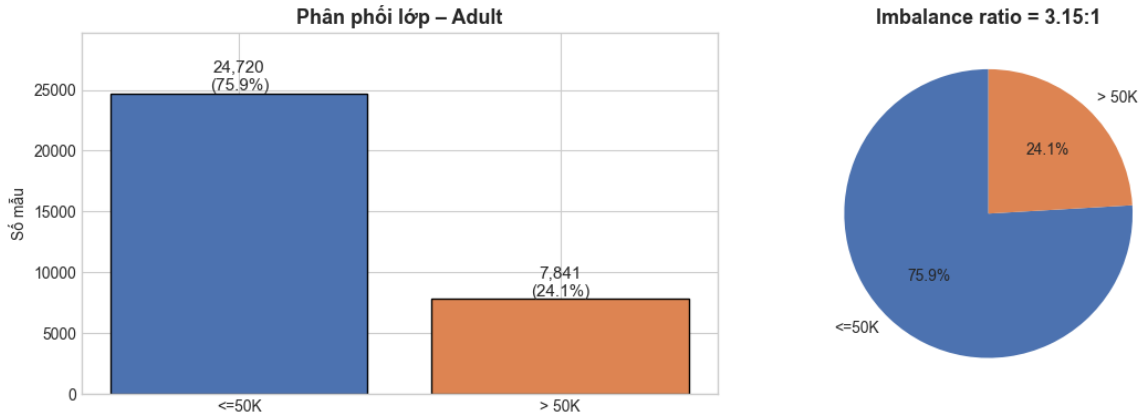

Hình 1: Phân phối lớp của Adult. Class $\leq 50K$ chiếm đa số nên Accuracy không đủ để đánh giá chất lượng mô hình.

2.1. Checklist yêu cầu

Yêu cầu	Trạng thái
Logistic Regression nhị phân bằng Gradient Descent	Đã cài đặt từ đầu với sigmoid và cross-entropy. Output LR-GD: Accuracy 0.8234, F1 0.5367.
Newton–Raphson / IRLS	Đã cài đặt Hessian/IRLS. Hội tụ sau 8 iterations. Output LR-Newton: Accuracy 0.8267, F1 0.5529.
Logistic Regression đa lớp	Đã so sánh softmax trực tiếp, one-vs-rest và one-vs-one trên dữ liệu tổng hợp 3 lớp.
Jacobian/Hessian softmax	Trình bày ở Mục 3.3.
LDA/QDA	Đã cài đặt LDA covariance chung và QDA covariance riêng từng lớp.
Fisher ratio và projection LDA	Đã tính Fisher ratio từng feature, xếp hạng, vẽ projection/decision boundary.

Perceptron	Đã chạy trên dữ liệu tuyến tính và moons phi tuyến. Tuyến tính hội tụ iteration 2; moons còn 64 lỗi.
L1/L2 regularization và stratified 5-fold CV	L2 tốt nhất $\lambda = 5.0$; L1 tốt nhất $\lambda = 0.001$.
Class-weighted loss	Recall lớp $> 50K$ tăng từ 0.4247 lên 0.7666.
Đánh giá mô hình	Có Accuracy, Precision, Recall, F1, confusion matrix, ROC/AUC, PR/AP, CV, McNemar, calibration.
Phần 4.1–4.4	Có kết nối GLM/exponential family, bảng so sánh, sensitivity/robustness và reproducibility.
Bonus	Có Probit, Laplace, Kernel Logistic Regression, GNB vs LDA và VC/SRM.

3. Xây dựng và huấn luyện mô hình

3.1. Logistic Regression nhị phân và Gradient Descent

Với $\tilde{x}_n = [1, x_n^T]^T$, Logistic Regression nhị phân mô hình hóa:

$$y_n = P(t_n = 1 \mid x_n) = \sigma(a_n) = \frac{1}{1 + e^{-a_n}}, \qquad a_n = \theta^T \tilde{x}_n. \tag{1}$$

Cross-entropy loss:

$$E(\theta) = -\sum_{n=1}^{N} \left[t_n \ln y_n + (1 - t_n) \ln(1 - y_n) \right]. \tag{2}$$

Gradient:

$$\nabla E(\theta) = \tilde{X}^T (y - t). \tag{3}$$

Gradient Descent cập nhật:

$$\theta^{(r+1)} = \theta^{(r)} - \eta \tilde{X}^T (y - t). \tag{4}$$

Ký hiệu và ý nghĩa.

- $\tilde{x}_n = [1, x_n^T]^T$ là vector đặc trưng của mẫu n sau khi thêm bias; $\tilde{X}$ là ma trận gom tất cả $\tilde{x}_n$.
- θ là vector trọng số cần học; $a_n = \theta^T \tilde{x}_n$ là logit hay điểm tuyến tính trước sigmoid.
- $y_n = \sigma(a_n)$ là xác suất mô hình dự đoán mẫu n thuộc lớp 1; $t_n \in \{0, 1\}$ là nhãn thật.
- Cross-entropy ở trên chính là negative log-likelihood của Bernoulli. Thành phần $(y - t)$ là sai lệch giữa xác suất dự đoán và nhãn thật, nên gradient có dạng rất trực quan: dữ liệu nhân với residual.

- η là learning rate. Nếu η quá lớn, loss dao động hoặc phân kỳ; nếu quá nhỏ, hội tụ chậm.

Output notebook cho LR-GD: Precision 0.7287, Recall 0.4247, F1 0.5367, Accuracy 0.8234, train time 0.826 giây, 300 iterations.

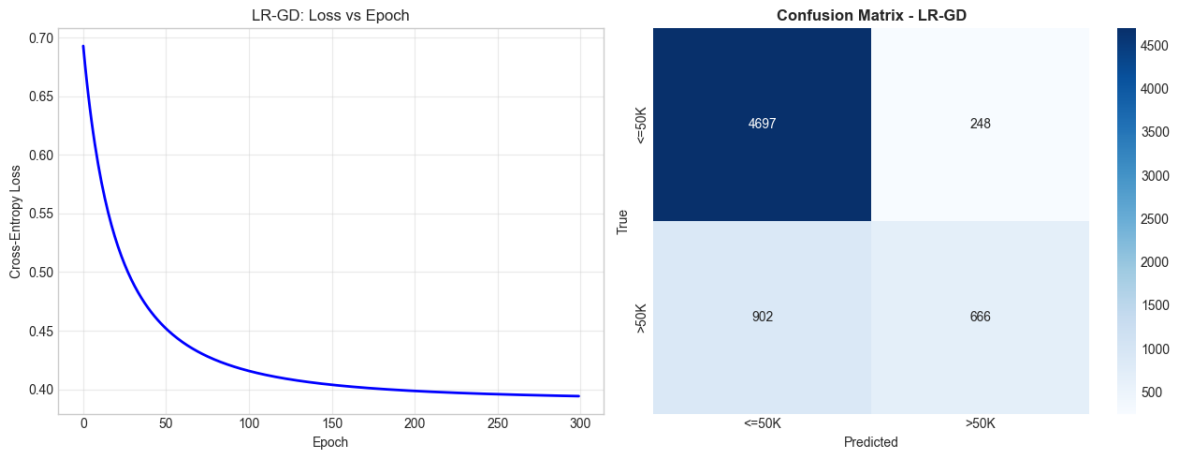

Hình 2: Loss curve và confusion matrix của LR-GD.

3.2. Newton–Raphson / IRLS

Hessian của Logistic Regression nhị phân:

$$H = \nabla^2 E(\theta) = \tilde{X}^T R \tilde{X}, \qquad R = \operatorname{diag}\left(y_n(1-y_n)\right). \tag{5}$$

Newton–Raphson:

$$\theta^{(r+1)} = \theta^{(r)} - H^{-1}\nabla E(\theta^{(r)}). \tag{6}$$

Dạng IRLS:

$$\theta^{(r+1)} = (\tilde{X}^T R \tilde{X})^{-1}\tilde{X}^T R z, \qquad z = \tilde{X}\theta^{(r)} + R^{-1}(t-y). \tag{7}$$

Ký hiệu và ý nghĩa.

- $R = \operatorname{diag}(y_n(1-y_n))$ là ma trận trọng số đường chéo. Giá trị $y_n(1-y_n)$ cũng là phương sai của Bernoulli tại mẫu n.
- Hessian $H = \tilde{X}^T R \tilde{X}$ mô tả độ cong của loss. Với Logistic Regression nhị phân, loss là hàm lồi nên Hessian bán xác định dương.
- z là pseudo-response trong IRLS. Mỗi bước Newton có thể nhìn như giải một bài toán weighted least squares với trọng số R và đáp ứng giả z.
- Khi xác suất gần 0 hoặc 1, $y_n(1-y_n)$ nhỏ, nghĩa là mẫu đó đóng góp ít hơn vào bước cập nhật IRLS; các mẫu gần biên quyết định có trọng số lớn hơn.

Output notebook: LR-Newton hội tụ ở iteration 8, Precision 0.7294, Recall 0.4452, F1 0.5529, Accuracy 0.8267, train time 0.050 giây. So với GD, Newton tốt hơn về F1 và nhanh hơn theo số epoch; đổi lại mỗi epoch tốn hơn vì cần Hessian.

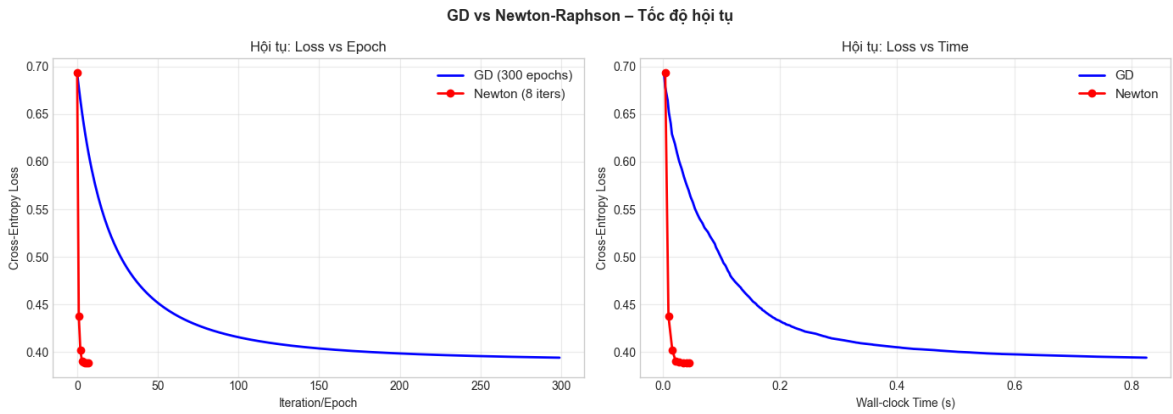

Hình 3: So sánh hội tụ của GD và Newton theo loss/epoch và loss/wall-clock time.

Phân tích. LR-GD và LR-Newton tối ưu cùng một hàm cross-entropy, nhưng Newton dùng thêm thông tin độ cong qua Hessian $H = X^T RX$. Trên Adult, số chiều sau xử lý chỉ khoảng $D = 12$, nên chi phí tính và nghịch đảo Hessian còn nhỏ. Vì vậy Newton hội tụ sau 8 iterations và đạt F1 0.5529, trong khi GD chạy 300 iterations và đạt F1 0.5367. Đây là trade-off giữa **chi phí mỗi bước** và **số bước cần thiết**: Newton đắt hơn mỗi bước nhưng cần rất ít bước; GD rẻ hơn nhưng phải đi nhiều epoch hơn. Nếu dữ liệu có hàng nghìn chiều, Newton có thể kém thực dụng hơn vì Hessian kích thước $D \times D$ quá lớn.

3.3. Softmax đa lớp, Jacobian và Hessian

Với K lớp, logits $a_k = w_k^T \tilde{x}$ và softmax:

$$y_k = P(t = k \mid x) = \frac{\exp(a_k)}{\sum_{j=1}^{K} \exp(a_j)}. \tag{8}$$

Cross-entropy đa lớp:

$$E(W) = -\sum_{n=1}^{N} \sum_{k=1}^{K} t_{nk} \ln y_{nk}. \tag{9}$$

Jacobian softmax:

$$\frac{\partial y_j}{\partial a_k} = y_j(\delta_{jk} - y_k), \qquad J = \mathrm{diag}(y) - yy^T. \tag{10}$$

Gradient theo w_k:

$$\frac{\partial E}{\partial w_k} = \sum_{n=1}^{N} (y_{nk} - t_{nk}) \tilde{x}_n. \tag{11}$$

Hessian block giữa lớp k và l:

$$H_{kl} = \frac{\partial^2 E}{\partial w_k \partial w_l^T} = \sum_{n=1}^{N} y_{nk}(\delta_{kl} - y_{nl}) \tilde{x}_n \tilde{x}_n^T. \tag{12}$$

Ký hiệu và ý nghĩa.

- K là số lớp; w_k là vector trọng số ứng với lớp k; $W = [w_1, \ldots, w_K]$ là toàn bộ tham số.

- t_{nk} là nhãn one-hot: $t_{nk} = 1$ nếu mẫu n thuộc lớp k, ngược lại bằng 0.
- δ_{jk} là Kronecker delta, bằng 1 khi $j = k$ và bằng 0 nếu khác lớp.
- Jacobian $J = \mathrm{diag}(y) - yy^T$ cho thấy xác suất các lớp không độc lập: tăng logit của một lớp sẽ làm giảm xác suất tương đối của các lớp còn lại.
- Hessian softmax có cấu trúc block H_{kl}: block đường chéo mô tả độ cong trong cùng lớp, block ngoài đường chéo mô tả tương tác cạnh tranh giữa hai lớp.

3.4. One-vs-rest, one-vs-one và softmax trực tiếp

Do Adult là nhị phân, notebook dùng dữ liệu tổng hợp 3 lớp để kiểm tra yêu cầu đa lớp.

Bảng 3: Output so sánh ba chiến lược đa lớp.

Chiến lược	Accuracy	Precision	Recall	F1
Softmax	**0.8400**	**0.8405**	**0.8400**	**0.8387**
OvR	0.8167	0.8186	0.8167	0.8142
OvO	0.8333	0.8368	0.8333	0.8311

Softmax trực tiếp tốt nhất vì tối ưu chung mọi lớp trong một loss. OvO tốt hơn OvR nhưng cần huấn luyện $K(K-1)/2$ classifier.

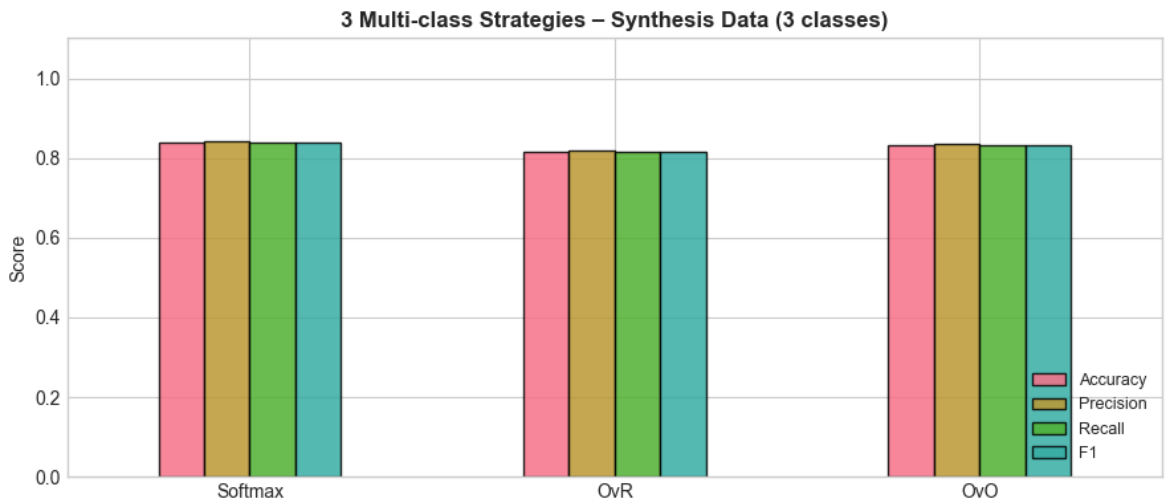

Hình 4: Metric của softmax, OvR và OvO trên dữ liệu tổng hợp 3 lớp.

3.5. LDA và QDA

LDA/QDA dùng Bayes:

$$P(y = k \mid x) \propto p(x \mid y = k)\pi_k, \qquad \hat{\pi}_k = \frac{N_k}{N}, \qquad \hat{\mu}_k = \frac{1}{N_k} \sum_{i:y_i=k} x_i. \tag{13}$$

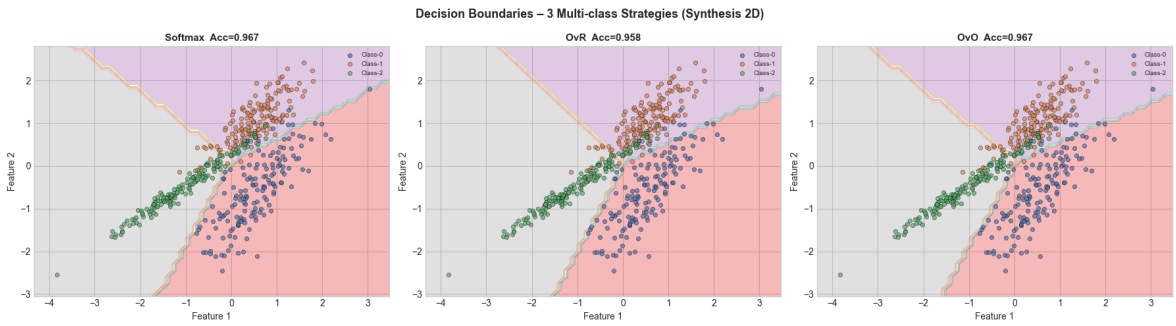

Hình 5: Decision boundary 2D cho ba chiến lược đa lớp.

LDA giả định covariance chung:

$$\hat{\Sigma} = \frac{1}{N-K} \sum_{k=1}^{K} \sum_{i:y_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T. \tag{14}$$

Hàm phân biệt LDA:

$$\delta_k(x) = x^T \hat{\Sigma}^{-1} \hat{\mu}_k - \frac{1}{2} \hat{\mu}_k^T \hat{\Sigma}^{-1} \hat{\mu}_k + \ln \hat{\pi}_k. \tag{15}$$

QDA dùng covariance riêng:

$$\hat{\Sigma}_k = \frac{1}{N_k - 1} \sum_{i:y_i=k} (x_i - \hat{\mu}_k)(x_i - \hat{\mu}_k)^T. \tag{16}$$

Hàm phân biệt QDA:

$$\delta_k(x) = -\frac{1}{2} \ln |\hat{\Sigma}_k| - \frac{1}{2} (x - \hat{\mu}_k)^T \hat{\Sigma}_k^{-1} (x - \hat{\mu}_k) + \ln \hat{\pi}_k. \tag{17}$$

Ký hiệu và ý nghĩa.

- N_k là số mẫu thuộc lớp k, N là tổng số mẫu; $\hat{\pi}_k = N_k/N$ là prior của lớp.
- $\hat{\mu}_k$ là vector trung bình của lớp k. Vector này cho biết tâm của phân phối feature trong từng lớp.
- $\hat{\Sigma}$ là covariance chung của LDA, được pooling từ tất cả lớp. Giả định này làm boundary của LDA là tuyến tính.
- $\hat{\Sigma}_k$ là covariance riêng của QDA. Vì covariance thay đổi theo lớp nên boundary của QDA là bậc hai.
- Term $\ln |\hat{\Sigma}_k|$ phạt các lớp có thể tích covariance lớn; term Mahalanobis distance đo khoảng cách từ x đến tâm lớp theo hình dạng covariance.

Output Adult: LDA Precision 0.7151, Recall 0.3858, F1 0.5012, Accuracy 0.8151. QDA Precision 0.6813, Recall 0.2972, F1 0.4139, Accuracy 0.7973. LDA có 103 tham số, QDA có 181 tham số. LDA tốt hơn QDA theo F1 trên Adult vì covariance giữa hai lớp không đủ khác biệt để QDA tận dụng ổn định.

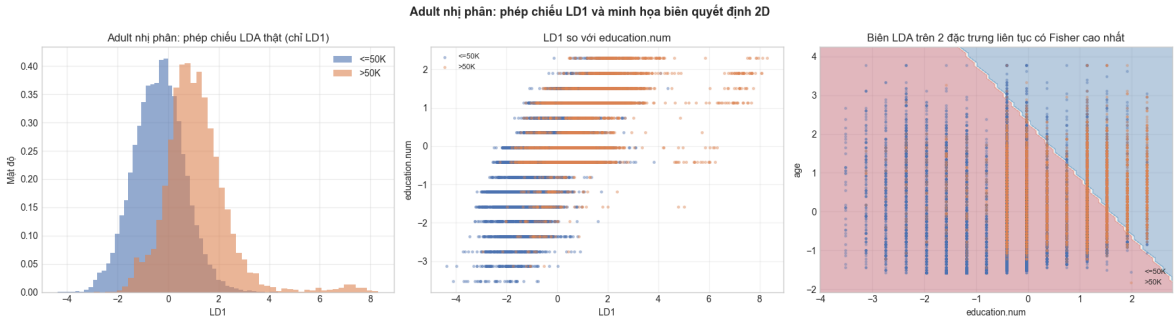

Hình 6: Projection LDA và minh họa decision boundary cho Adult nhị phân.

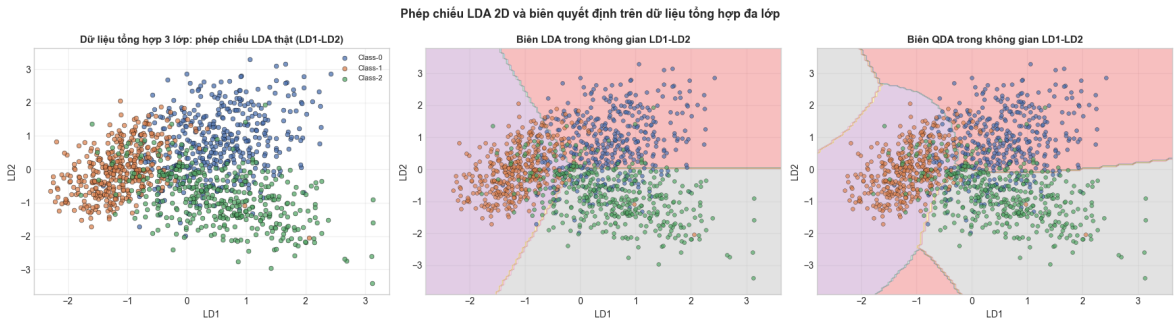

Hình 7: LDA projection xuống 2D và decision boundary LDA/QDA trên dữ liệu tổng hợp.

Phân tích. LDA tốt hơn QDA theo F1 trên Adult dù QDA linh hoạt hơn. Lý do là QDA cần ước lượng covariance riêng cho từng lớp, nên nhiều tham số hơn và dễ lệch threshold hơn khi dữ liệu mất cân bằng. LDA dùng covariance chung nên ổn định hơn, đồng thời vẫn giữ được tương quan giữa feature. Kết quả này cũng giải thích vì sao LDA có F1 0.5012 cao hơn GNB: GNB bỏ qua off-diagonal covariance, trong khi output covariance cho thấy một số feature tương quan mạnh, ví dụ capital_net và capital.gain.

3.6. Fisher ratio

Fisher ratio cho từng feature trong bài toán nhị phân:

$$J_j = \frac{(\mu_{1j} - \mu_{0j})^2}{\sigma_{1j}^2 + \sigma_{0j}^2}. \tag{18}$$

Top feature theo output notebook: education.num 0.123314, relationship 0.071070, age 0.056185, hours.per.week 0.055765, capital.gain 0.052973.

Ký hiệu và ý nghĩa.

- μ_{1j} và μ_{0j} là trung bình của feature j ở lớp 1 và lớp 0.
- σ_{1j}^2 và σ_{0j}^2 là phương sai trong từng lớp. Mẫu số càng lớn thì hai lớp càng chồng lấn trên feature đó.
- J_j lớn khi khoảng cách giữa hai trung bình lớp lớn và phương sai nội lớp nhỏ. Do đó Fisher ratio đo độ tách lớp của từng feature riêng lẻ.
- Vì feature đã được chuẩn hóa trước khi huấn luyện, ranking Fisher ratio phản ánh discriminability tương đối thay vì bị chi phối bởi đơn vị đo.

Bảng 4: Xếp hạng Fisher ratio trên Adult.

Hạng	Feature	J_j	Hạng	Feature	J_j
1	education.num	0.123314	7	capital_net	0.048501
2	relationship	0.071070	8	capital.loss	0.025562
3	age	0.056185	9	race	0.005422
4	hours.per.week	0.055765	10	occupation	0.001124
5	capital.gain	0.052973	11	fnlwgt	0.000118
6	sex	0.049976	12	workclass	0.000011

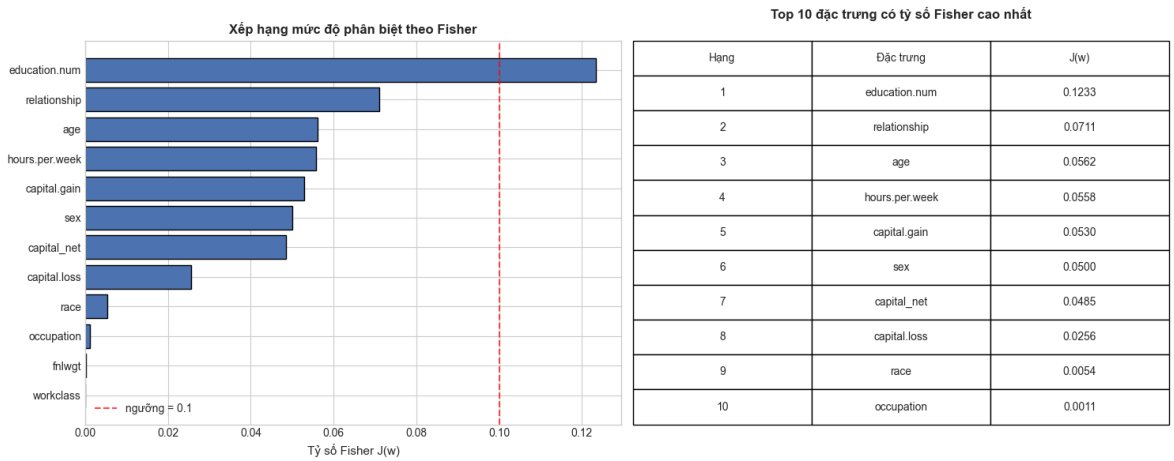

Hình 8: Fisher ratio của từng đặc trưng.

3.7. Perceptron và regularization

Perceptron với $y_n \in \{-1, +1\}$ cập nhật khi mẫu sai:

$$w \leftarrow w + \eta y_n x_n, \qquad b \leftarrow b + \eta y_n. \tag{19}$$

Output: linearly separable final errors = 0, epochs = 2; non-linear moons final errors = 64, không hội tụ.

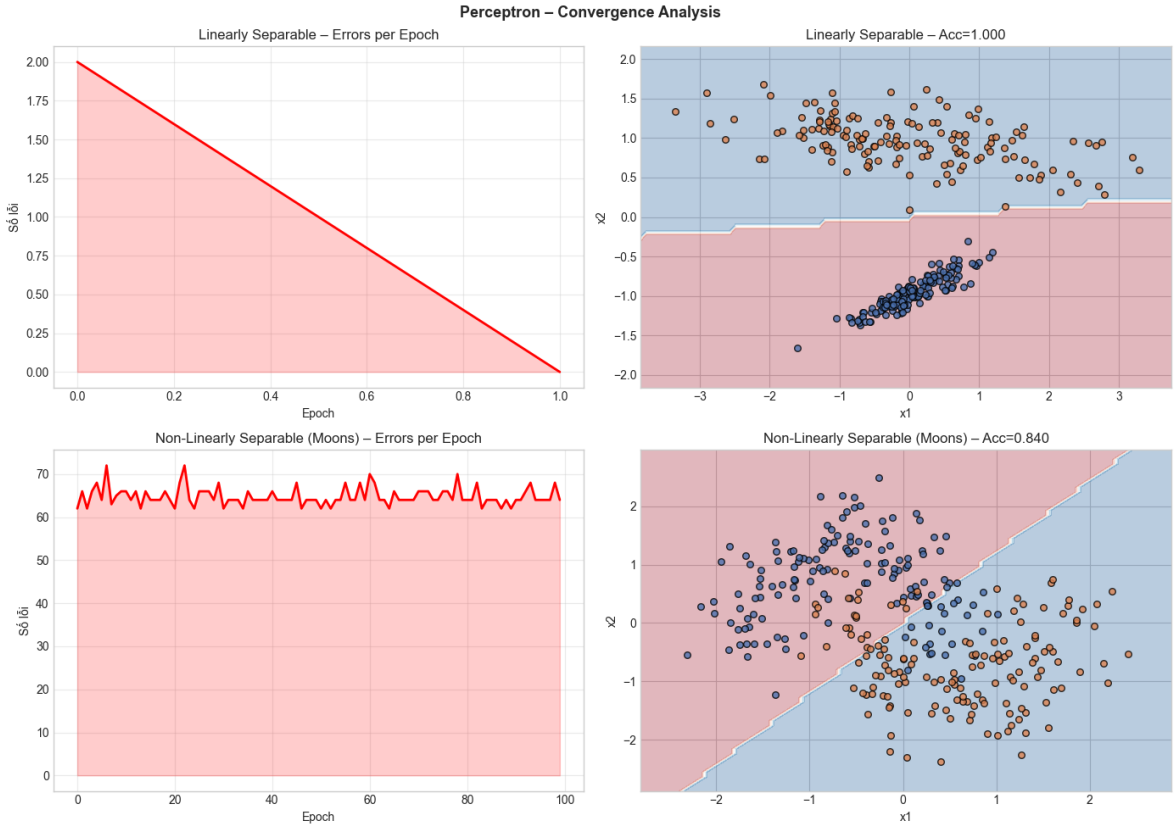

Hình 9: Perceptron trên dữ liệu tuyến tính và phi tuyến.

Regularized Logistic Regression:

$$E_{L2}(\theta) = E(\theta) + \frac{\lambda}{2N}\|\theta\|_2^2, \tag{20}$$

$$E_{L1}(\theta) = E(\theta) + \frac{\lambda}{N}\|\theta\|_1. \tag{21}$$

Output CV chống rò rỉ tiền xử lý: L1 tốt nhất $\lambda = 0.001$, F1 0.5344 ± 0.0125; L2 tốt nhất $\lambda = 5.0$, F1 0.5345 ± 0.0126. Trên test set, L2 có F1 0.5361, L1 có F1 0.5367.

Ký hiệu và ý nghĩa.

- λ điều khiển độ mạnh của regularization. $\lambda = 0$ tương ứng không phạt; λ quá lớn có thể làm mô hình underfit.
- $\|\theta\|_2^2$ phạt bình phương trọng số, làm các hệ số co đều về 0 nhưng thường không bằng 0 tuyệt đối.

- $\|\theta\|_1$ phạt tổng trị tuyệt đối trọng số, có xu hướng tạo nghiệm thưa, phù hợp khi muốn feature selection.
- Chia penalty cho N giúp độ lớn loss ổn định hơn khi số mẫu thay đổi giữa các fold CV.

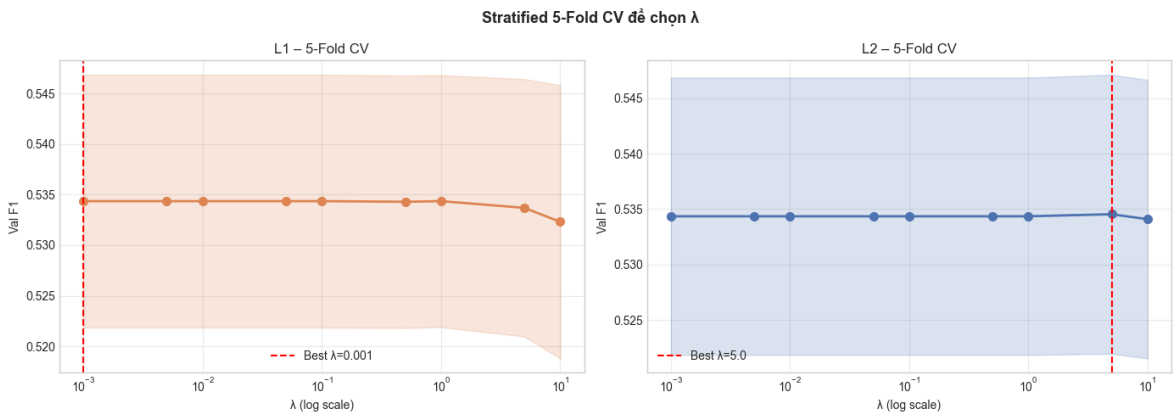

Hình 10: Stratified 5-fold CV chọn λ cho L1 và L2.

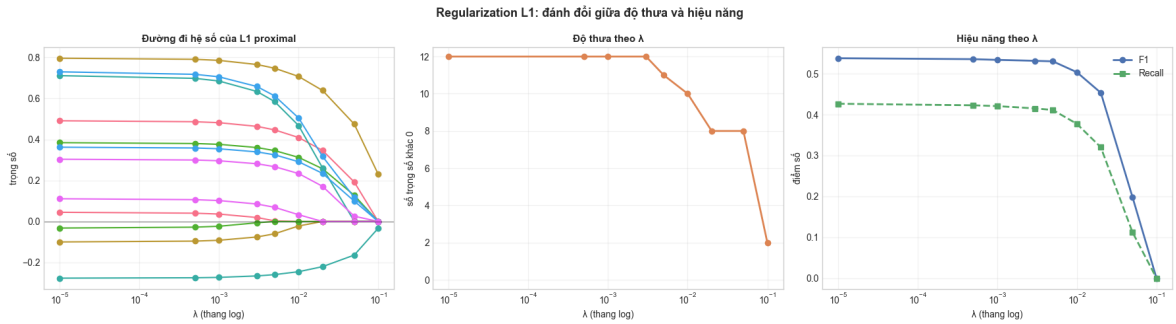

Hình 11: Đường đi sparsity của L1 proximal.

Class-weighted loss:

$$E = -\sum_{n=1}^{N}\sum_{k=1}^{K} c_k t_{nk} \ln y_{nk}, \qquad c_k \propto \frac{N}{N_k}. \tag{22}$$

Output: không trọng số Accuracy 0.8234, F1 0.5367, Precision 0.7287, Recall 0.4247. Có trọng số lớp Accuracy 0.7631, F1 0.6091, Precision 0.5053, Recall 0.7666, với $c_0 = 1.317$, $c_1 = 4.152$.

Trong công thức trên, c_k là trọng số lỗi của lớp k. Lớp càng ít mẫu thì N_k càng nhỏ, nên c_k càng lớn. Với Adult, lớp $> 50K$ là lớp thiểu số nên lỗi trên lớp này được phạt mạnh hơn, làm mô hình tăng Recall cho lớp dương.

Phân tích. Regularization L1/L2 đúng về mặt phương pháp nhưng ít làm thay đổi hiệu năng vì dữ liệu hiện tại có số feature thấp và train size lớn, nên overfitting không phải vấn đề chính. Ngược lại, class weighting tạo tác động rất rõ vì nó thay đổi trực tiếp chi phí lỗi giữa hai lớp. Recall lớp $> 50K$ tăng từ 0.4247 lên 0.7666, nhưng Precision giảm từ 0.7287 xuống 0.5053. Đây không phải cải thiện miễn phí mà là dịch chuyển decision boundary có chủ đích: phù hợp khi cần hạn chế bỏ sót lớp thiểu số, nhưng không phù hợp nếu false positive có chi phí cao.

Kết luận phần. Trong nhóm mô hình chính, LR-Newton là baseline mạnh nhất về cân bằng Accuracy/F1 và tốc độ hội tụ; LDA hữu ích nhất cho phân tích discriminability qua Fisher ratio; class-weighted Logistic Regression là lựa chọn phù hợp khi cần tăng Recall lớp thiểu số. Perceptron cho thấy rõ giới hạn của mô hình tuyến tính trên dữ liệu không phân chia tuyến tính.

4. Bonus models

4.1. Probit

Probit dùng Gaussian CDF:

$$P(y = 1 \mid x) = \Phi(\theta^T x). \tag{23}$$

Output test: Precision 0.7346, Recall 0.4184, F1 0.5331, Accuracy 0.8236. Với nhiễu nhãn, Probit thấp hơn Logistic ở mọi mức noise trong output.

Ở đây $\Phi(\cdot)$ là cumulative distribution function của chuẩn tắc. Logistic Regression dùng sigmoid còn Probit dùng Gaussian CDF; cả hai đều ánh xạ logit tuyến tính về xác suất $[0, 1]$, nhưng Gaussian CDF có tail mỏng hơn sigmoid nên phản ứng với điểm rất xa biên hơi khác.

Bảng 5: Logistic vs Probit khi tăng label noise.

Noise	Logistic F1	Probit F1	Δ Probit–LR
0%	0.5313	0.5305	-0.0008
5%	0.5238	0.5134	-0.0104
10%	0.5094	0.4830	-0.0264
20%	0.4851	0.4698	-0.0153
30%	0.4689	0.4596	-0.0093

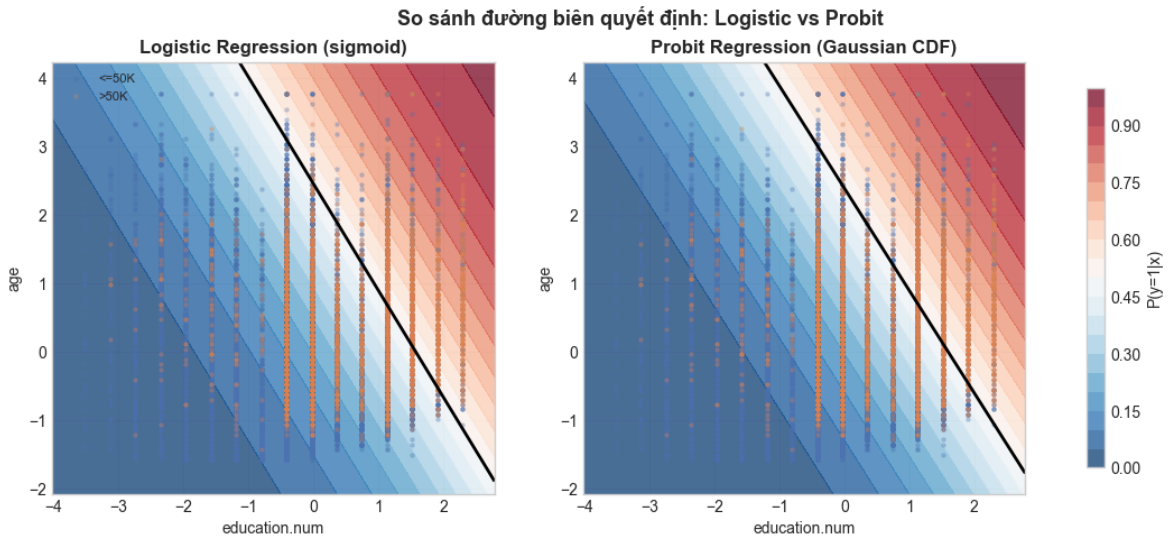

Hình 12: Đường biên quyết định và xác suất đầu ra của Probit so với Logistic Regression.

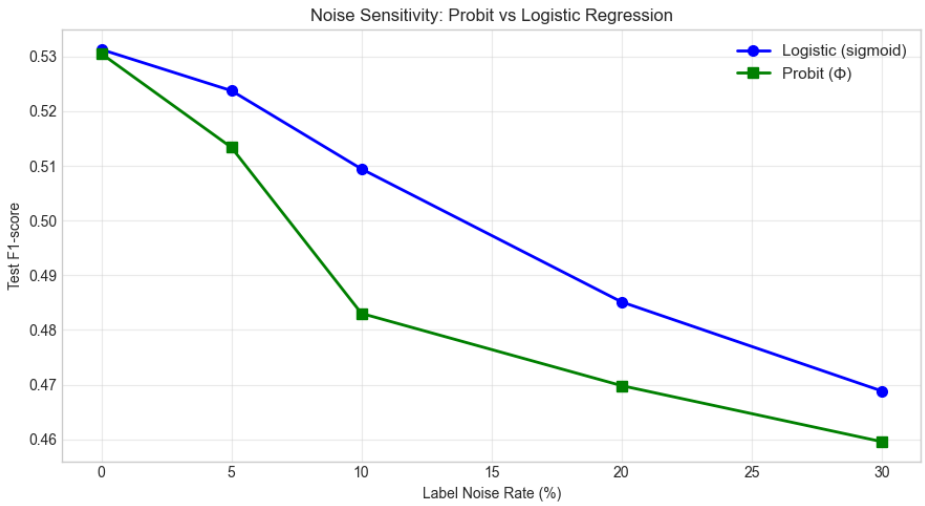

Hình 13: Độ nhạy với label noise của Probit và Logistic Regression.

4.2. Laplace approximation

Với prior Gaussian $p(\theta) = \mathcal{N}(0, \alpha^{-1}I)$:

$$E_{MAP}(\theta) = E(\theta) + \frac{\alpha}{2}\theta^T\theta, \qquad A = \nabla^2 E_{MAP}(\theta_{MAP}) = X^T RX + \alpha I. \tag{24}$$

Posterior xấp xỉ:

$$p(\theta \mid \mathcal{D}) \approx \mathcal{N}(\theta_{MAP}, A^{-1}), \qquad \sigma_a^2(x_*) = x_*^T A^{-1} x_*. \tag{25}$$

Output Laplace: Precision 0.7298, Recall 0.4152, F1 0.5293, Accuracy 0.8222. Vùng màu cam trong hình là nơi $p(x) \pm 2\sigma(x)$ chứa ngưỡng 0.5.

Ký hiệu và ý nghĩa.

- θ_{MAP} là tham số tại cực đại posterior, tương đương nghiệm tối ưu có thêm Gaussian prior.
- A là Hessian của negative log posterior tại MAP. Ma trận nghịch đảo A^{-1} đóng vai trò covariance của posterior Gaussian xấp xỉ.
- $\sigma_a^2(x_*)$ là độ bất định của logit tại điểm mới x_*. Nếu khoảng $p(x) \pm 2\sigma(x)$ cắt ngưỡng 0.5 thì mô hình chưa chắc chắn về quyết định phân lớp.

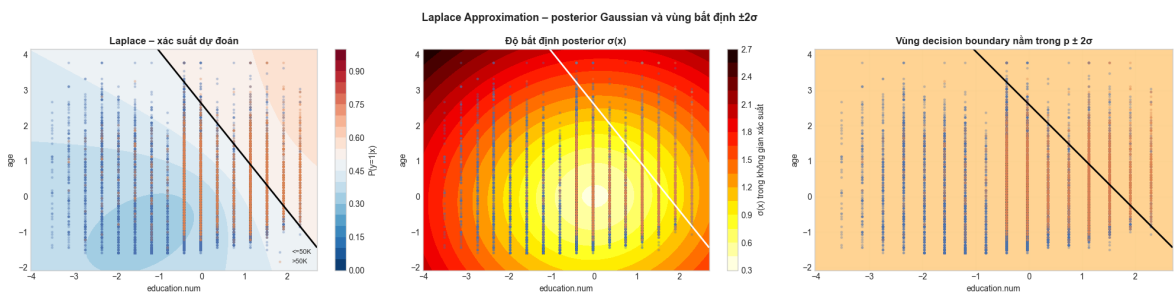

Hình 14: Laplace approximation và vùng bất định $p \pm 2\sigma$ của decision boundary.

4.3. Kernel Logistic Regression

Kernel LR dùng:

$$f(x) = \sum_{i=1}^{N} \alpha_i K(x_i, x), \qquad K(x_i, x_j) = \exp\left(-\gamma \|x_i - x_j\|^2\right). \tag{26}$$

Output XOR-like: Linear LR Accuracy 0.3667, F1 0.3214, Recall 0.3103; Kernel LR Accuracy 0.8667, F1 0.8462, Recall 0.7586. Kernel LR giải quyết phi tuyến tốt hơn nhưng cần Gram matrix $N \times N$, memory $O(N^2)$.

Trong công thức trên, α_i là hệ số dual ứng với mẫu train x_i, còn $K(x_i, x)$ đo độ tương tự giữa mẫu train và điểm cần dự đoán. RBF kernel có tham số γ: γ lớn làm vùng ảnh hưởng của từng điểm hẹp hơn, γ nhỏ làm boundary mượt hơn.

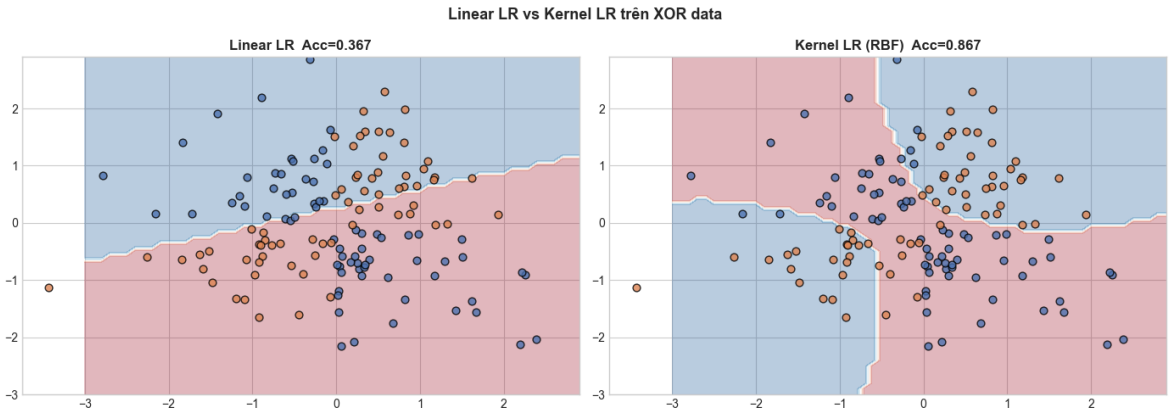

Hình 15: Kernel LR học tốt pattern XOR-like, còn LR tuyến tính thất bại.

4.4. GNB vs LDA

GNB giả định độc lập có điều kiện:

$$p(x \mid y = k) = \prod_{j=1}^{D} \mathcal{N}(x_j; \mu_{kj}, \sigma_{kj}^2). \tag{27}$$

LDA giữ full covariance chung. Output Adult: GNB Accuracy 0.7941, F1 0.4095, Precision 0.6615, Recall 0.2966; LDA Accuracy 0.8151, F1 0.5012, Precision 0.7151, Recall 0.3858. LDA thắng vì các feature có correlation, ví dụ capital_net và capital.gain có $r = 0.998$.

Với GNB, mỗi feature x_j được mô hình hóa bằng một Gaussian riêng trong từng lớp và các feature được xem là độc lập khi đã biết nhãn. Giả định này giúp mô hình rất nhanh và ít tham số, nhưng bỏ qua correlation giữa các feature. LDA không giả định independence; covariance chung giữ được các tương quan tuyến tính nhưng cần ước lượng nhiều tham số hơn.

4.5. VC dimension và SRM

Với linear classifier trong $\mathbb{R}^D$:

$$VC(\mathcal{H}_{linear}) = D + 1. \tag{28}$$

Bảng 6: Thí nghiệm có kiểm soát cho GNB vs LDA.

Setting	GNB mean	GNB std	LDA mean	Winner
Độc lập + phương sai riêng	0.8423	0.0260	0.7069	GNB
Ít mẫu, nhiều chiều	0.5757	0.0654	0.5500	GNB
Tương quan mạnh, tín hiệu lệch pha	0.9017	0.0499	0.9605	LDA
Tương quan theo cặp	0.9682	0.0194	0.9903	LDA

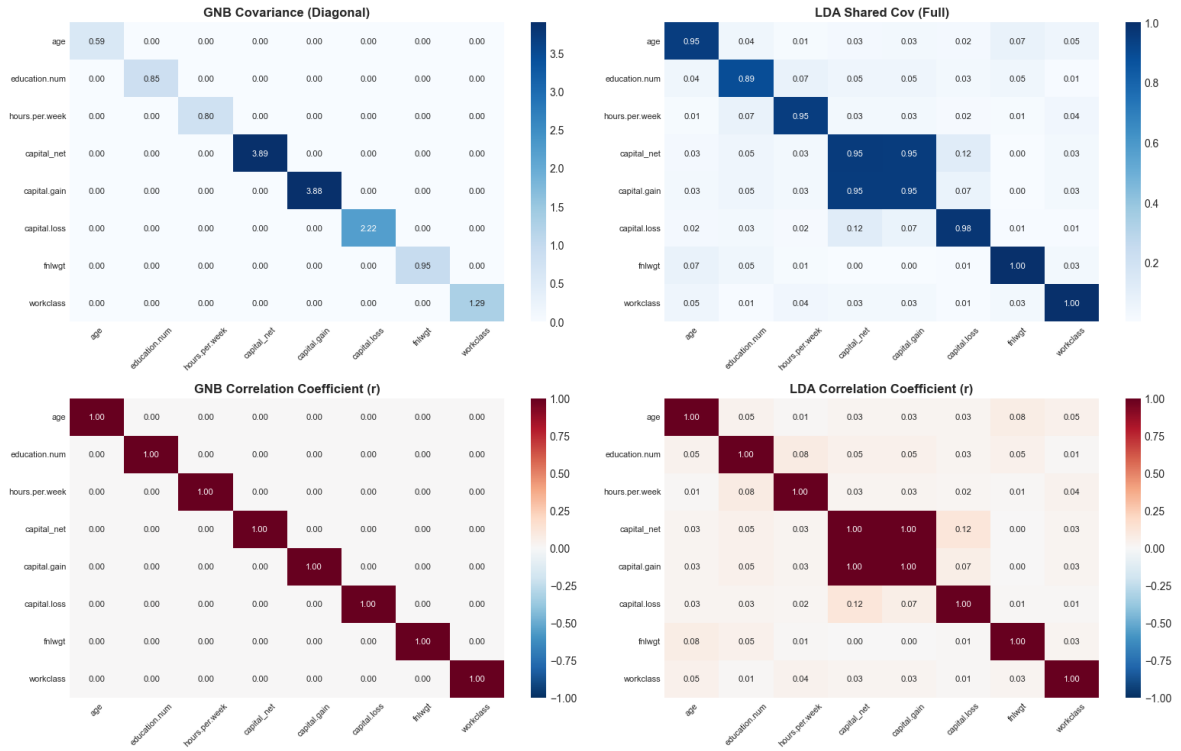

Hình 16: GNB dùng covariance diagonal, LDA dùng full covariance.

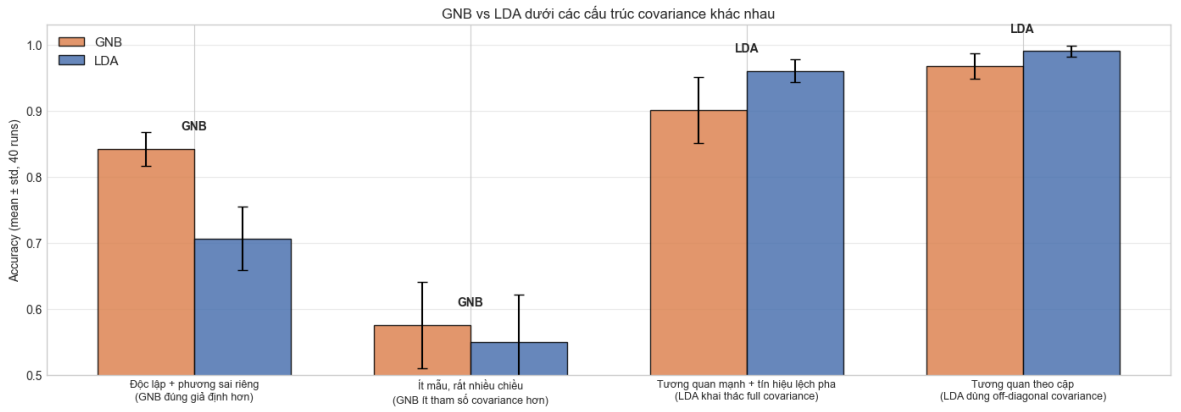

Hình 17: Thí nghiệm có kiểm soát: GNB tốt hơn khi giả định diagonal/N nhỏ đúng hơn; LDA tốt hơn khi correlation hữu ích.

Adult có $D = 12$, nên VC dimension là 13. Cận SRM dùng trong code:

$$R(h) \leq \hat{R}(h) + \sqrt{\frac{VC(\mathcal{H})\left(\ln \frac{2m}{VC(\mathcal{H})} + 1\right) + \ln \frac{4}{\delta}}{m}}. \tag{29}$$

Output: với $\delta = 0.05$, SRM bound $= 0.0736$. Cách diễn giải này dựa trên khung Statistical Learning Theory và VC dimension [8].

Ký hiệu và ý nghĩa.

- $R(h)$ là true risk, tức lỗi kỳ vọng trên phân phối dữ liệu thật; $\hat{R}(h)$ là empirical risk trên train set.
- $VC(\mathcal{H})$ đo độ phức tạp của lớp mô hình. Với hyperplane tuyến tính trong $\mathbb{R}^D$, VC dimension là $D + 1$.
- m là số mẫu train, δ là mức rủi ro của bound. Bound đúng với xác suất ít nhất $1 - \delta$.
- Khi m tăng, penalty giảm; khi số chiều D tăng, VC dimension tăng và cần nhiều dữ liệu hơn để giữ khả năng tổng quát hóa.

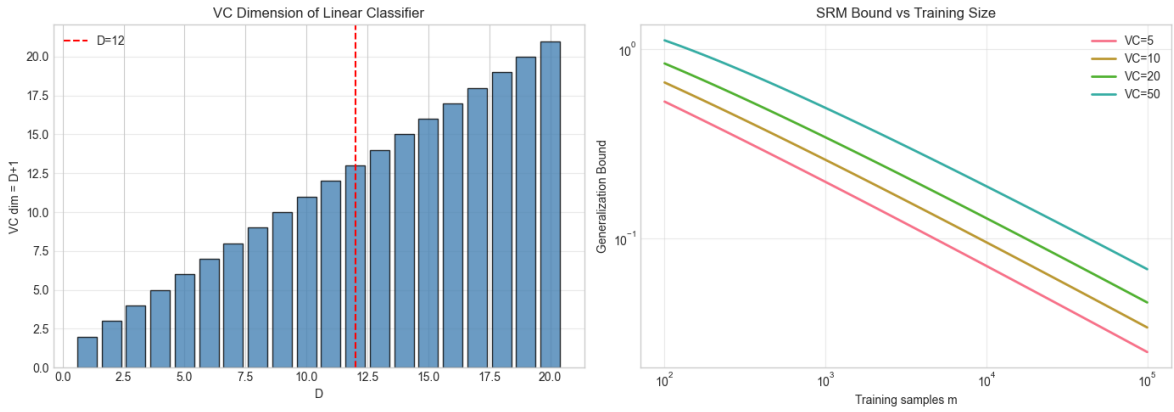

Hình 18: VC dimension và cận SRM theo số mẫu.

Kết luận phần. Các mô hình bonus bổ sung góc nhìn ngoài baseline tuyến tính: Probit kiểm tra link function khác sigmoid; Laplace cung cấp bất định posterior quanh decision boundary; Kernel LR chứng minh sức mạnh của phi tuyến trên XOR-like pattern; GNB vs LDA làm rõ vai trò của giả định independence/covariance; VC/SRM kết nối số chiều, số mẫu và khả năng tổng quát hóa.

5. Đánh giá mô hình

5.1. Metric và công thức

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}, \tag{30}$$

$$Precision = \frac{TP}{TP + FP}, \tag{31}$$

$$Recall = \frac{TP}{TP + FN}, \tag{32}$$

$$F1 = \frac{2\,Precision\,Recall}{Precision + Recall}. \tag{33}$$

ROC/AUC đánh giá ranking xác suất khi thay đổi threshold [4]. Precision–Recall/AP phù hợp hơn khi lớp dương hiếm [5]. Reliability diagram kiểm tra calibration bằng cách so confidence dự đoán với tần suất dương thực tế [6].

Ký hiệu và ý nghĩa.

- TP là số mẫu dương dự đoán đúng; TN là số mẫu âm dự đoán đúng.
- FP là false positive, tức mẫu âm bị dự đoán thành dương; FN là false negative, tức mẫu dương bị dự đoán thành âm.
- Precision trả lời: trong các mẫu dự đoán là dương, bao nhiêu mẫu thật sự dương. Recall trả lời: trong các mẫu dương thật, mô hình bắt được bao nhiêu.
- F1 là trung bình điều hòa của Precision và Recall, phù hợp hơn Accuracy khi dữ liệu mất cân bằng.

5.2. Bảng test metrics thống nhất

Bảng 7: Test metrics của toàn bộ mô hình classification.

Model	Accuracy	Precision	Recall	F1	AUC	AP
LR-GD	0.8234	0.7287	0.4247	0.5367	0.8449	0.6782
LR-Newton	**0.8267**	0.7294	0.4452	0.5529	0.8468	**0.6885**
LDA	0.8151	0.7151	0.3858	0.5012	0.8364	0.6417
QDA	0.7973	0.6813	0.2972	0.4139	**0.8526**	0.6751
Probit	0.8236	**0.7346**	0.4184	0.5331	0.8468	0.6800
Laplace	0.8222	0.7298	0.4152	0.5293	0.8417	0.6687
L2 ($\lambda = 5.0$)	0.8233	0.7284	0.4241	0.5361	0.8449	0.6781
L1 ($\lambda = 0.001$)	0.8234	0.7287	0.4247	0.5367	0.8449	0.6782
LR-Weighted	0.7631	0.5053	**0.7666**	**0.6091**	0.8465	0.6725
GNB	0.7941	0.6615	0.2966	0.4095	0.8280	0.6480

Phân tích. Không có một mô hình duy nhất tốt nhất cho mọi mục tiêu. Nếu ưu tiên hiệu năng tổng thể ở threshold mặc định 0.5, LR-Newton là lựa chọn cân bằng nhất với Accuracy 0.8267 và F1 0.5529. Nếu ưu tiên phát hiện lớp thiểu số $> 50K$, LR-Weighted tốt hơn rõ rệt với Recall 0.7666 và F1 lớp dương 0.6091. Nếu mục tiêu là ranking xác suất, QDA đáng chú ý vì AUC cao nhất 0.8526 dù F1 chỉ 0.4139. Điều này cho thấy QDA xếp hạng mẫu khá tốt nhưng threshold mặc định chưa phù hợp với phân phối xác suất hoặc chi phí sai lầm của bài toán.

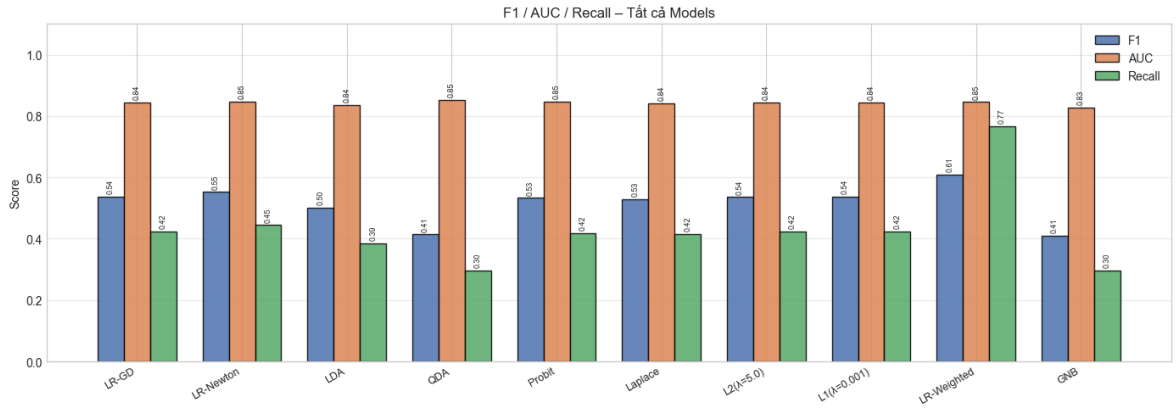

Hình 19: Bar chart so sánh metric giữa các mô hình.

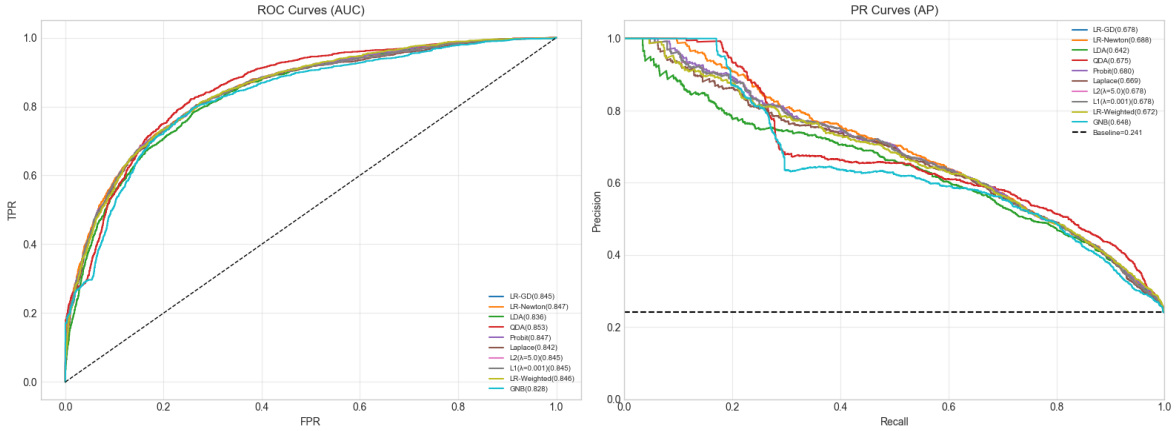

Hình 20: ROC curve, AUC, Precision–Recall curve và AP.

Nhận xét về xác suất đầu ra. ROC/AUC và PR/AP đánh giá khả năng ranking, còn calibration cho biết xác suất dự đoán có đáng tin hay không. Một mô hình có AUC cao vẫn có thể calibration kém; khi đó xác suất 0.8 không nhất thiết tương ứng với khoảng 80% mẫu dương. Vì vậy nếu dùng xác suất để ra quyết định, cần xem reliability diagram và có thể tune threshold hoặc calibration hậu xử lý như Platt scaling/isotonic regression.

5.3. Per-class metrics và CV

Phân tích mất cân bằng lớp. Adult có lớp $> 50K$ chỉ chiếm 24.07% trên test set. Vì vậy Accuracy dễ lạc quan: LR-GD đạt Accuracy 0.8234 nhưng Recall lớp dương chỉ 0.4247, tức bỏ sót hơn một nửa mẫu $> 50K$. LR-Weighted giảm Accuracy xuống 0.7631

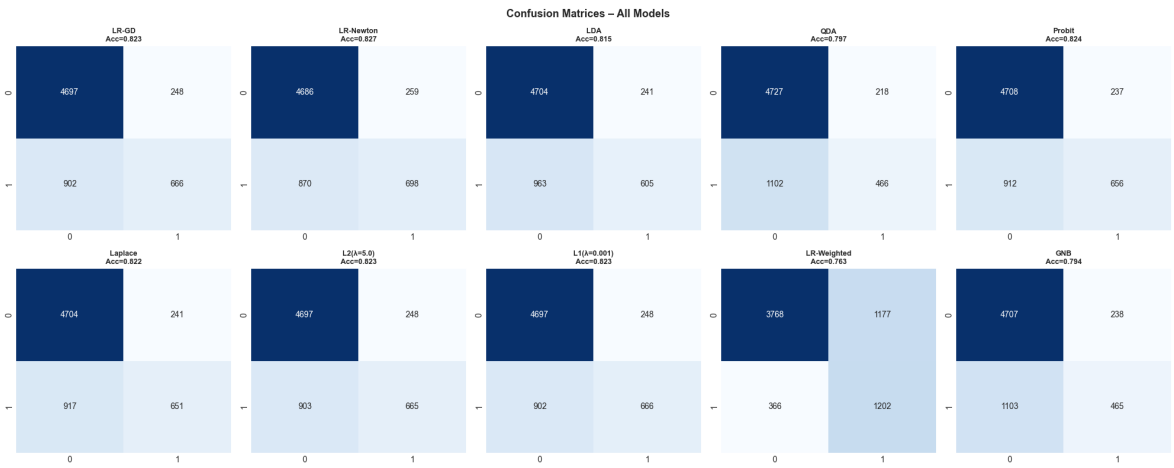

Hình 21: Confusion matrix heatmap của các mô hình.

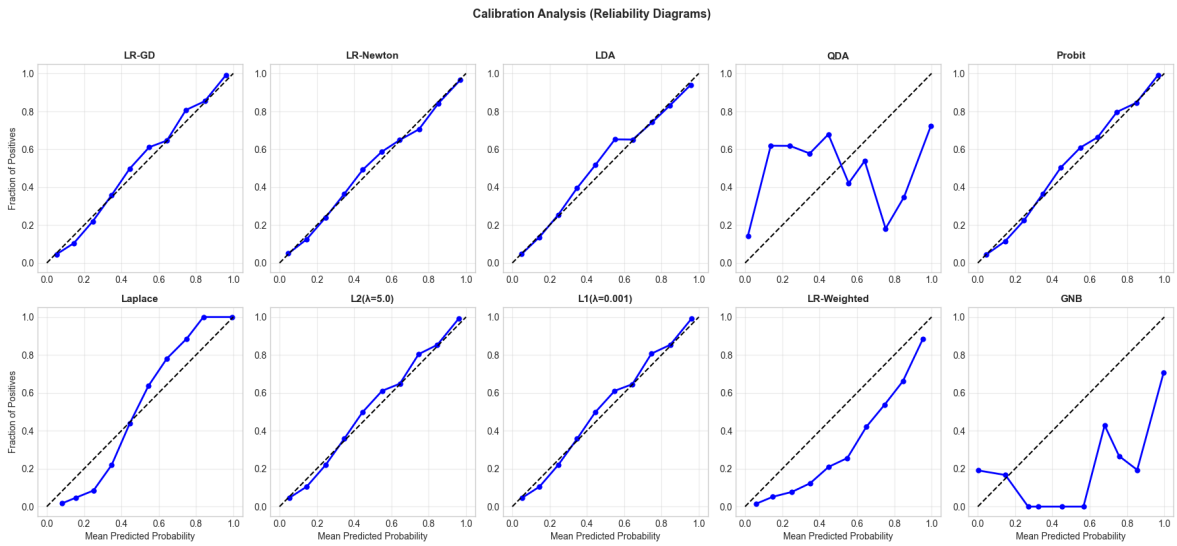

Hình 22: Reliability diagram để phân tích calibration.

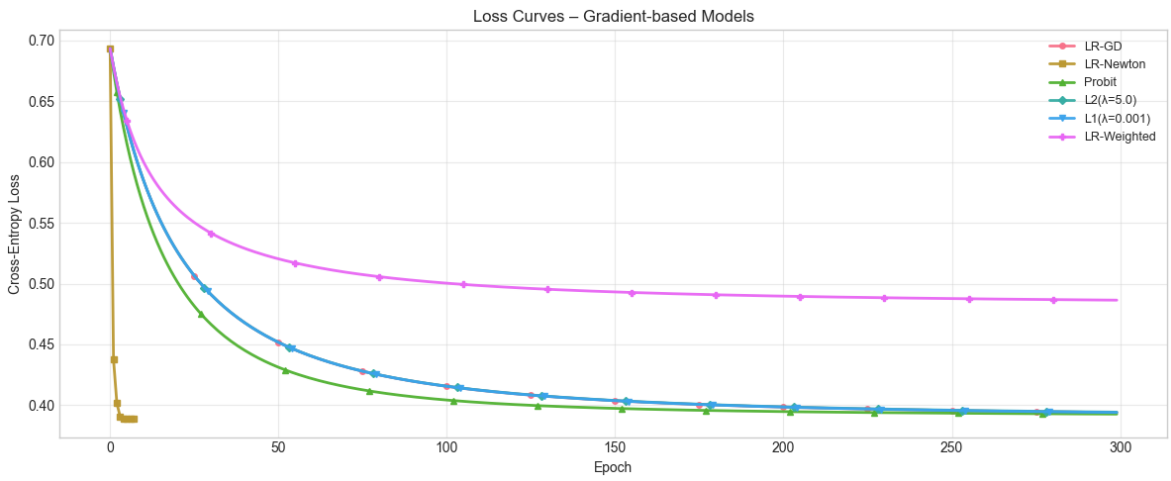

Hình 23: Loss curve của các thuật toán lặp.

Bảng 8: Top mô hình theo F1 lớp $> 50K$.

Model	Prec. lớp 1	Rec. lớp 1	F1 lớp 1	Balanced Acc.
LR-Weighted	0.5053	**0.7666**	**0.6091**	**0.7643**
LR-Newton	0.7294	0.4452	0.5529	0.6964
LR-GD	0.7287	0.4247	0.5367	0.6873
L1 ($\lambda = 0.001$)	0.7287	0.4247	0.5367	0.6873
L2 ($\lambda = 5.0$)	0.7284	0.4241	0.5361	0.6870

Bảng 9: Stratified 5-fold CV: mean ± std.

Model	Accuracy	Precision	Recall	F1	AUC	AP
LR-GD	0.8229 ± 0.0029	0.7283 ± 0.0051	0.4221 ± 0.0144	0.5344 ± 0.0125	0.8447 ± 0.0044	0.6753 ± 0.0095
LR-Newton	0.8272 ± 0.0027	0.7283 ± 0.0079	0.4507 ± 0.0098	0.5568 ± 0.0088	0.8477 ± 0.0039	0.6873 ± 0.0089
LDA	0.8135 ± 0.0032	0.7069 ± 0.0081	0.3851 ± 0.0148	0.4985 ± 0.0136	0.8359 ± 0.0040	0.6422 ± 0.0096
QDA	0.8038 ± 0.0029	0.7054 ± 0.0126	0.3185 ± 0.0107	0.4387 ± 0.0114	0.8576 ± 0.0084	0.6819 ± 0.0092
GNB	0.7992 ± 0.0038	0.6785 ± 0.0180	0.3163 ± 0.0094	0.4314 ± 0.0113	0.8337 ± 0.0086	0.6575 ± 0.0111
Probit	0.8232 ± 0.0031	0.7309 ± 0.0065	0.4207 ± 0.0155	0.5338 ± 0.0132	0.8457 ± 0.0038	0.6755 ± 0.0094
Laplace	0.8213 ± 0.0033	0.7220 ± 0.0064	0.4190 ± 0.0155	0.5302 ± 0.0138	0.8428 ± 0.0050	0.6702 ± 0.0095
L2 ($\lambda = 5.0$)	0.8231 ± 0.0030	0.7290 ± 0.0051	0.4221 ± 0.0144	0.5345 ± 0.0126	0.8447 ± 0.0044	0.6752 ± 0.0095
L1 ($\lambda = 0.001$)	0.8229 ± 0.0029	0.7283 ± 0.0051	0.4221 ± 0.0144	0.5344 ± 0.0125	0.8447 ± 0.0044	0.6753 ± 0.0095
LR-Weighted	0.7620 ± 0.0027	0.5038 ± 0.0035	0.7710 ± 0.0130	0.6094 ± 0.0064	0.8443 ± 0.0039	0.6666 ± 0.0102

nhưng tăng Recall lên 0.7666 và F1 lớp dương lên 0.6091. Do đó trong bài toán này, F1 lớp dương, Recall, Balanced Accuracy, PR curve và AP phản ánh chất lượng mô hình tốt hơn Accuracy đơn lẻ.

5.4. McNemar's test

McNemar kiểm định hai mô hình trên cùng test set và thường được dùng để so sánh paired classifiers [7]. Với b và c là hai loại bất đồng:

$$\chi^2 = \frac{(|b - c| - 1)^2}{b + c}. \tag{34}$$

Output: LR-GD vs LR-Newton $\chi^2 = 4.8193$, $p = 0.028143$; LDA vs LR-GD $\chi^2 = 18.2403$, $p = 0.000019$; GNB vs LDA $\chi^2 = 23.2654$, $p = 0.000001$; L2($\lambda = 5.0$) vs LR-GD $\chi^2 = 0.0000$, $p = 1.000000$.

Trong đó b là số mẫu mô hình thứ nhất dự đoán đúng nhưng mô hình thứ hai sai, còn c là số mẫu mô hình thứ nhất sai nhưng mô hình thứ hai đúng. Nếu $p < 0.05$, ta có bằng chứng rằng hai mô hình khác biệt có ý nghĩa thống kê trên cùng test set.

Phân tích kiểm định. McNemar's test giúp tránh kết luận dựa trên chênh lệch metric rất nhỏ. LR-Newton khác LR-GD có ý nghĩa thống kê ($p = 0.028143$), nên cải thiện của Newton không chỉ là dao động ngẫu nhiên trên test set. Ngược lại, L2($\lambda = 5.0$) và LR-GD có $p = 1.000000$, phù hợp với việc hai mô hình có bảng metric gần như trùng nhau.

5.5. Phân tích lỗi

Error analysis cho L2-LR cho thấy 1151/6513 mẫu test bị sai (17.7%). Trong đó 903 lỗi (78.5%) là class $> 50K$ bị dự đoán thành $\leq 50K$. Nhóm bị sai có age cao hơn (43.90 so với 37.69), education.num cao hơn (11.02 so với 9.88), hours.per.week cao hơn (45.23 so với 39.49), nhưng capital_net thấp hơn nhiều (389.78 so với 1080.49). Điều này gợi ý rằng mô hình tuyến tính dựa mạnh vào các tín hiệu capital gain/loss; các cá nhân có tuổi, học vấn và giờ làm tương đối cao nhưng không có tín hiệu vốn rõ ràng dễ rơi vào vùng biên.

Về mặt mô hình, đây là dấu hiệu thiếu interaction phi tuyến, ví dụ age × education hoặc occupation × hours.per.week. Một tuyến tính đơn giản khó biểu diễn các luật kiểu giờ làm cao chỉ có ý nghĩa trong một số nhóm nghề. Đây là lý do Kernel LR thắng lớn trên XOR-like pattern, nhưng đổi lại khó giải thích và tốn $O(N^2)$ memory.

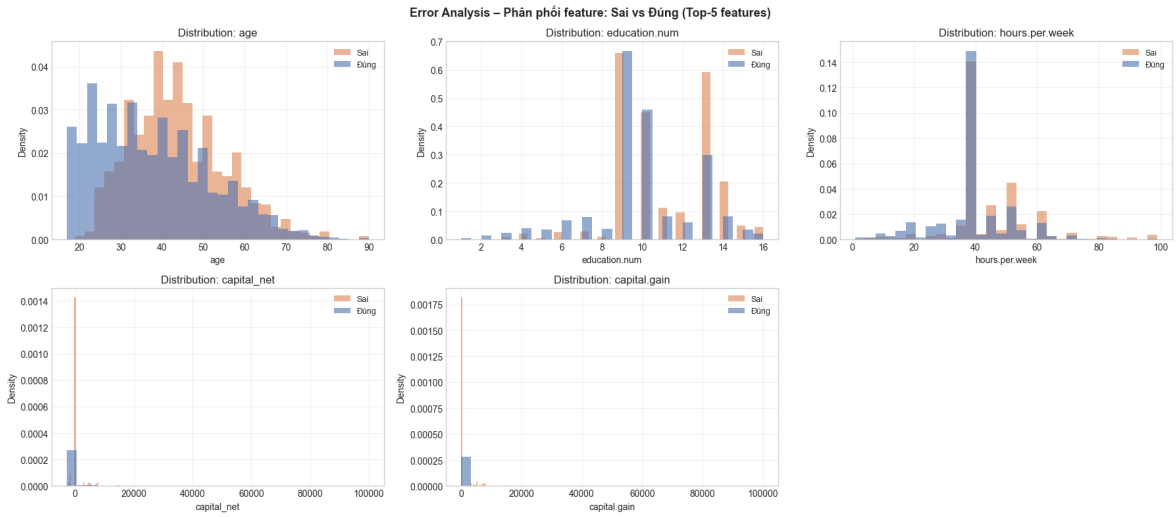

Hình 24: Phân tích phân phối feature của nhóm sai và nhóm đúng.

Kết luận phần. Đánh giá trên test set và CV cho thấy LR-Newton là mô hình không weighting ổn định nhất, còn LR-Weighted tốt nhất khi ưu tiên lớp $> 50K$. Các chỉ số AUC/AP, calibration, McNemar và error analysis giúp tránh kết luận hời hợt chỉ dựa trên Accuracy: QDA ranking tốt nhưng F1 thấp, L2 gần như không khác LR-GD, và phần lớn lỗi nằm ở các mẫu class 1 vùng biên.

6. Phân tích so sánh và kỹ năng nghiên cứu

Phần này được tích hợp vào report classification như tiêu chí chất lượng. Vì report này không phải report tổng hồi quy + phân lớp, các kết nối với hồi quy được trình bày ở mức lý thuyết; số thực nghiệm chi tiết vẫn tập trung vào classification.

6.1. Kết nối hồi quy và phân lớp

Logistic Regression là hồi quy theo nghĩa mô hình hóa kỳ vọng có điều kiện của biến Bernoulli:

$$E[y \mid x] = P(y = 1 \mid x) = \sigma(\theta^T x). \tag{35}$$

Linear Regression và Logistic Regression đều thuộc GLM, một khung thống nhất cho các mô hình xác suất thuộc exponential family [3]:

$$g(\mu) = \theta^T x, \qquad \mu = E[y \mid x]. \tag{36}$$

Linear Regression dùng Gaussian likelihood và identity link $g(\mu) = \mu$. Logistic Regression dùng Bernoulli likelihood và logit link:

$$g(\mu) = \log \frac{\mu}{1-\mu} = \theta^T x. \tag{37}$$

Softmax Regression mở rộng sang Categorical/Multinomial.

Ở đây μ là kỳ vọng có điều kiện của biến mục tiêu. Với hồi quy tuyến tính, μ có thể nhận giá trị thực bất kỳ. Với Logistic Regression, $\mu = P(y = 1 \mid x)$ là xác suất nên phải nằm trong $[0, 1]$; logit link biến xác suất này về miền số thực để khớp với predictor tuyến tính $\theta^T x$.

Gaussian, Bernoulli và Categorical đều thuộc exponential family:

$$p(y \mid \eta) = h(y) \exp\left(\eta^T T(y) - A(\eta)\right). \tag{38}$$

Vì vậy Linear Regression, Logistic Regression và Softmax Regression có cấu trúc thống nhất: likelihood sinh loss, gradient thường có dạng dự đoán trừ nhãn, và link function nối mean parameter với linear predictor.

Trong công thức exponential family, η là natural parameter, $T(y)$ là sufficient statistic, $A(\eta)$ là log-partition function đảm bảo phân phối chuẩn hóa, còn $h(y)$ là base measure. Cùng một khung này sinh ra squared error cho Gaussian và cross-entropy cho Bernoulli/Categorical.

6.2. Bảng so sánh toàn diện

Bảng 10: Bảng so sánh tổng quát giữa nhóm hồi quy và nhóm phân lớp.

Tiêu chí	**Linear / Ridge / Lasso**	**Logistic / LDA / QDA**
Giả thiết phân phối	Linear Regression giả định Gaussian noise. Ridge/Lasso giữ giả định này nhưng thêm penalty/prior lên hệ số.	Logistic học Bernoulli/Categorical $P(y \mid x)$. LDA/QDA giả định Gaussian theo lớp; LDA dùng shared covariance, QDA dùng class-specific covariance.
Nghiệm dạng đóng	Linear Regression có nghiệm normal equation; Ridge cũng có nghiệm đóng. Lasso thường cần solver lặp do penalty L1 không trơn.	Logistic không có nghiệm đóng, dùng GD/Newton/IRLS. LDA/QDA có nghiệm dạng ước lượng mean, covariance và prior.

Tiêu chí	Linear / Ridge / Lasso	Logistic / LDA / QDA
Độ phức tạp	Giải trực tiếp thường khoảng $O(ND^2 + D^3)$; Ridge tương tự, Lasso phụ thuộc thuật toán tối ưu.	Logistic GD: $O(ND)$ mỗi epoch; Newton: $O(ND^2 + D^3)$ mỗi epoch. LDA: $O(ND^2 + D^3)$; QDA cần thêm covariance từng lớp.
Khả năng giải thích	Cao vì hệ số tuyến tính đọc trực tiếp được; Lasso còn hỗ trợ chọn feature.	Logistic giải thích qua log-odds; LDA giải thích tốt qua Fisher ratio/projection; QDA khó hơn vì boundary bậc hai.
Nhạy với outlier	Linear/Ridge/Lasso vẫn nhạy với outlier; Ridge giảm variance nhưng không loại bỏ ảnh hưởng điểm ngoại lai.	Logistic nhạy với điểm xa boundary; LDA/QDA nhạy vì mean và covariance bị kéo bởi outlier.
Hiệu năng thực nghiệm	Không lặp số regression trong report classification này.	LR-Newton F1 0.5529; LR-Weighted F1 0.6091; LDA F1 0.5012; QDA F1 0.4139.

6.3. Sensitivity và robustness

Bảng 11: F1 trung bình khi thay đổi train/test split.

Split	GNB	L2-LR	LDA	LR-Newton
60/40	0.4225	0.5366	0.5036	0.5548
70/30	0.4231	0.5382	0.5040	0.5553
80/20	0.4194	0.5387	0.5039	0.5562

Độ ổn định theo mean/std F1: LR-Newton 0.5554 ± 0.0036, L2-LR 0.5379 ± 0.0060, GNB 0.4217 ± 0.0068, LDA 0.5039 ± 0.0077. LR-Newton ổn định nhất vì khi train size thay đổi, nghiệm Newton vẫn tối ưu cùng objective lồi của Logistic Regression và không phụ thuộc mạnh vào ước lượng covariance như LDA. LDA có độ lệch chuẩn cao nhất trong nhóm này, phù hợp với việc covariance estimate nhạy hơn khi split thay đổi.

Bảng 12: F1 khi thêm Gaussian noise vào feature đã chuẩn hóa.

σ	GNB	L2-LR	LDA	LR-Newton
0.0	0.4093	0.5347	0.5021	0.5524
0.1	0.4082	0.5340	0.5025	0.5508
0.5	0.3910	0.4865	0.4522	0.4906
1.0	0.3567	0.3649	0.3441	0.3634

Mức giảm F1 trung bình so với baseline sạch: GNB 0.0240, LDA 0.0691, L2-LR 0.0729, LR-Newton 0.0842. Theo drop nhỏ, GNB robust nhất với Gaussian noise, dù F1 tuyệt đối

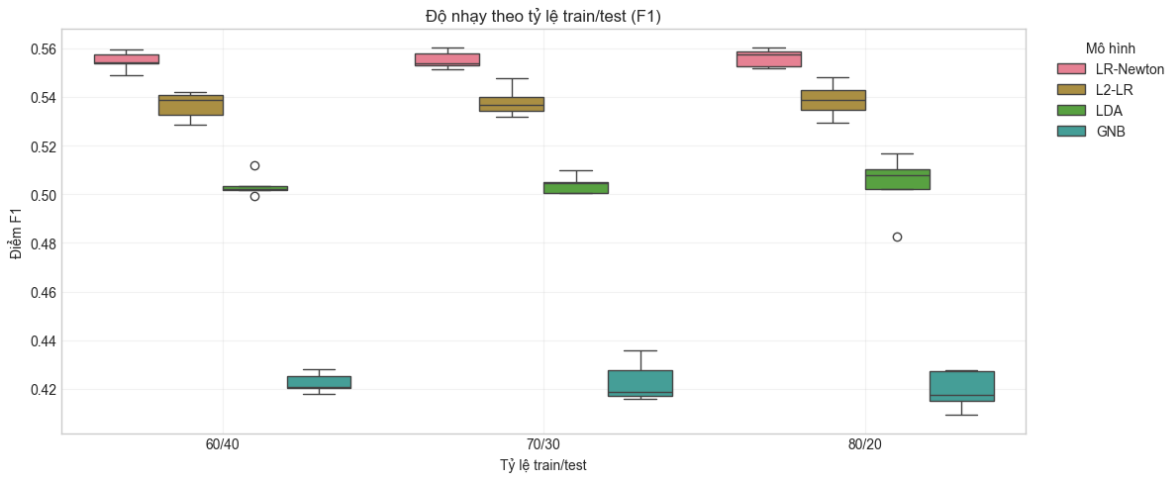

Hình 25: Boxplot F1 theo train/test split và seed.

ban đầu thấp hơn. Đây là ví dụ cần phân biệt giữa robustness tương đối và hiệu năng tuyệt đối: GNB giảm ít vì mô hình vốn đơn giản và có F1 thấp hơn, còn LR-Newton giảm nhiều hơn nhưng vẫn là mô hình tốt ở vùng noise nhỏ.

Feature corruption: xóa 10%, 20%, 30% giá trị feature. F1 trung bình theo imputer: KNN 0.4587, mean 0.4518, median 0.4483; KNN tốt nhất vì tận dụng cấu trúc lân cận giữa các mẫu thay vì thay toàn bộ missing bằng một thống kê toàn cục. Tuy nhiên KNN imputation tốn chi phí hơn mean/median và có thể kém ổn định khi dữ liệu rất lớn. Mức giảm F1 trung bình: GNB 0.0309, LR-Newton 0.0490, L2-LR 0.0528, LDA 0.0541.

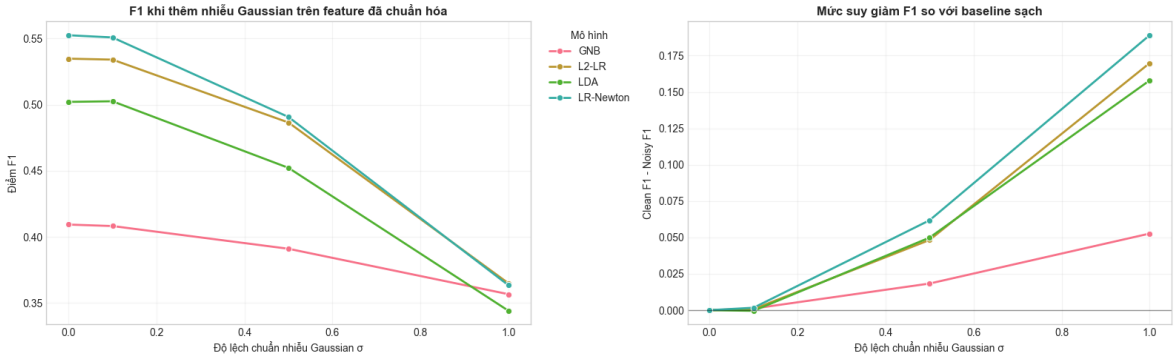

Hình 26: F1/drop khi thêm noise và làm hỏng feature.

Bảng 13: Tóm tắt hội tụ.

Model	Epochs	Best loss	Best epoch	Epoch 1%	Test F1
LR-Newton	8	0.388734	8	4	0.5524
L2-LR	300	0.393878	300	207	0.5363
LR-GD	300	0.393636	300	208	0.5361
L1-LR	300	0.393636	300	208	0.5361
Probit	300	0.395128	300	215	0.5291

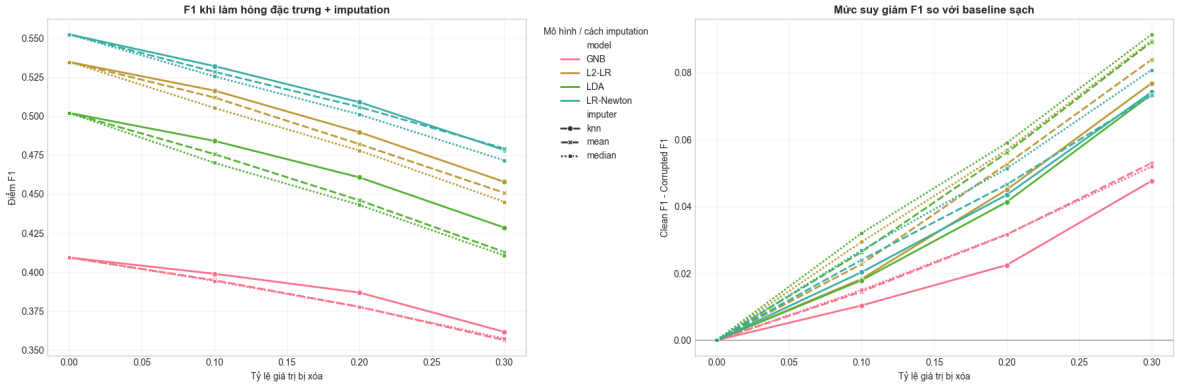

Hình 27: So sánh mean, median và KNN imputation.

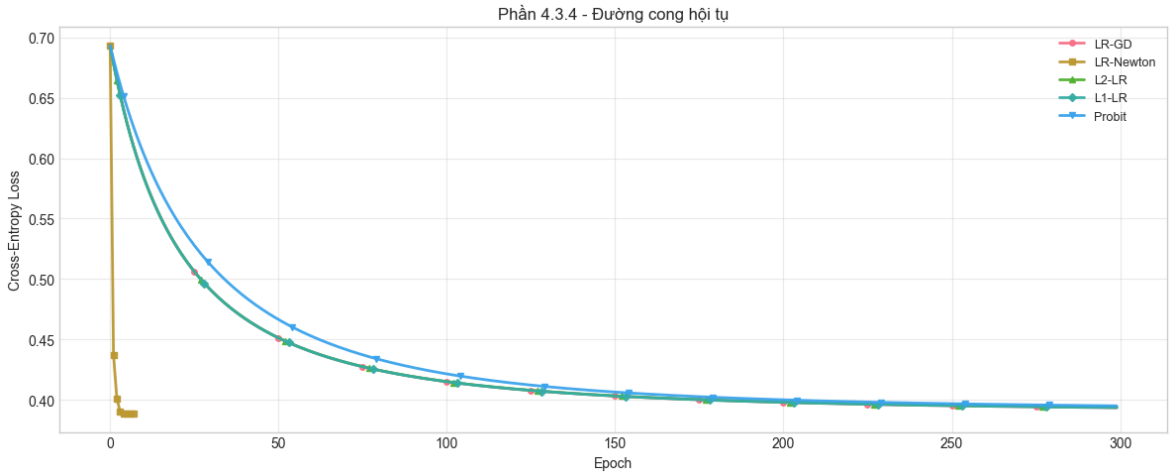

Hình 28: Loss curve cho các thuật toán lặp trong phần convergence.

6.4. Khả năng tái hiện

Notebook cố định seeds 13, 42, 77, 123, 2026. Các log nằm ở `code/Part2_Classification/artifacts/section4_classification`: split indices, metrics từng run, hyperparameters, convergence losses, runtime/memory summary và manifest. File `requirements.txt` ở root đã ghim version package chính.

Bảng 14: Runtime/memory mean trong các kịch bản chính.

Scenario	Model	Train time mean (s)	Peak memory mean (MB)
clean baseline	GNB	0.0074	3.6865
clean baseline	L2-LR	0.5769	4.4547
clean baseline	LDA	0.0074	4.2744
clean baseline	LR-Newton	0.0565	8.6141
noise injection	GNB	0.0082	3.6865
noise injection	L2-LR	0.6021	4.4544
noise injection	LDA	0.0076	4.2745
noise injection	LR-Newton	0.0702	8.6148
split sensitivity	GNB	0.0072	3.2339
split sensitivity	L2-LR	0.5405	3.9079
split sensitivity	LDA	0.0068	3.7410
split sensitivity	LR-Newton	0.0653	7.5459

Chạy lại notebook từ đầu trong cùng môi trường package sẽ tái hiện đầy đủ vì scaler được fit trong từng fold/split, random seed được cố định và split indices đã được lưu.

Kết luận phần. Phần so sánh cho thấy classification không tách rời hồi quy: Logistic Regression là GLM với Bernoulli likelihood, còn Linear Regression dùng Gaussian likelihood. Robustness experiments cho thấy LR-Newton ổn định nhất theo split, GNB giảm F1 ít nhất khi thêm noise nhưng hiệu năng tuyệt đối thấp hơn, và KNN imputation tốt nhất khi feature bị corruption. Các artifact log, seeds và requirements giúp kết quả có thể chạy lại được.

7. Kết luận classification

Tất cả yêu cầu classification chính, bonus và phần 4.1–4.4 đã được bao phủ. Điểm quan trọng nhất không chỉ là LR-Newton có Accuracy/F1 cao, mà là mỗi mô hình thể hiện một trade-off khác nhau. LR-Newton là lựa chọn cân bằng nhất khi dùng threshold mặc định: Accuracy 0.8267, F1 0.5529. LR-Weighted là lựa chọn tốt nhất khi ưu tiên lớp thiểu số: Recall 0.7666, F1 0.6091. LDA/QDA/GNB có giá trị phân tích theo hướng generative; LDA tốt hơn GNB/QDA theo F1 trên Adult, còn QDA có AUC cao nhất nhưng cần threshold tuning. Kernel LR chứng minh lợi ích của phi tuyến trên XOR-like pattern, còn Laplace cung cấp thông tin bất định quanh decision boundary.

Nếu phải chọn mô hình để báo cáo như baseline chính, nhóm chọn **LR-Newton** vì hội tụ nhanh, kết quả ổn định, dễ giải thích và có kiểm định McNemar ủng hộ khác biệt so với LR-GD. Nếu mục tiêu nghiệp vụ ưu tiên không bỏ sót lớp $> 50K$, nhóm chọn **LR-Weighted** và chấp nhận Precision thấp hơn. Đây là kết luận gắn với metric, chi phí sai lầm và đặc điểm dữ liệu, thay vì chỉ nhìn một chỉ số Accuracy.

Tài liệu tham khảo

Tài liệu

[1] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.

[2] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, 2nd ed. Springer, 2009.

[3] K. P. Murphy, *Machine Learning: A Probabilistic Perspective*. MIT Press, 2012.

[4] T. Fawcett, "An introduction to ROC analysis,"*Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.

[5] J. Davis and M. Goadrich, "The relationship between Precision-Recall and ROC curves,"in *Proceedings of ICML*, 2006.

[6] A. Niculescu-Mizil and R. Caruana, "Predicting good probabilities with supervised learning,"in *Proceedings of ICML*, 2005.

[7] T. G. Dietterich, "Approximate statistical tests for comparing supervised classification learning algorithms,"*Neural Computation*, vol. 10, no. 7, pp. 1895–1923, 1998.

[8] V. N. Vapnik, *Statistical Learning Theory*. Wiley, 1998.